

**MULTI-TASK LEARNING KLASIFIKASI CLICKBAIT DAN
KATEGORI BERITA INDONESIA**



DISUSUN OLEH:

FARHAN PURWANTO MARULITUA	(247056015)
FIKRI HANIF	(247056016)
MARDANAN FITRA	(247056019)

**PROGRAM STUDI S2 SAINS DATA DAN KECERDASAN BUATAN
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA**

MEDAN

2025

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR TABEL	iv
DAFTAR GAMBAR	v
BAB I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	2
1.4 Manfaat Penelitian	2
1.5 Batasan Penelitian	3
BAB II Landasan Teori.....	4
2.1 Pengertian dan Konsep Dasar	4
2.1.1 <i>Clickbait</i>	4
2.1.2 <i>BERT</i>	4
2.1.3 Klasifikasi Kategori Berita	4
2.1.4 <i>Multi-Task Learning</i>	5
2.2 Penelitian Terkini	6
BAB III METODOLOGI PENELITIAN	7
3.1 Jenis Penelitian.....	7
3.2 Pendekatan	7
3.3 Data	7
3.3.1 Sumber Data.....	7
3.3.2 Karakteristik Data.....	7
3.3.3 Pra-pemrosesan Data.....	8
3.3.4 Pembagian Dataset.....	8
3.4 Arsitektur Umum Sistem	8
3.5 Arsitektur Model	12
3.5.1 Model Indobert	12
3.5.2 Model Dasar (Backbone)	14
3.5.3 Struktur Head Multitask	14
3.6 Proses Pelatihan	15
3.6.1 Tokenisasi	15
3.6.2 Strategi Pelatihan.....	15
3.6.3 Konfigurasi Hyperparameter	15
3.7 Lingkungan Komputasi	15
BAB IV HASIL DAN PEMBAHASAN	16
4.1 Hasil Pelatihan	16

4.1.1	Grafik Training vs Validation Loss (per Epoch)	16
4.1.2	Grafik Training Loss (Gabungan, Clickbait, & Kategori)	17
4.2	Hasil Evaluasi Model	17
4.2.1	Classification Report - Clickbait	17
4.2.2	Classification Report - Kategori Berita	18
4.2.3	Confusion Matrix Clickbait	19
4.2.4	Confusion Matrix - Kategori Berita	20
BAB V	Kesimpulan dan Saran	21
5.1	Kesimpulan	21
5.2	Saran	21
DAFTAR PUSTAKA		24
LAMPIRAN		L-1
L.1	Percobaan Pertama	L-1
L.2	Percobaan Tiga	L-4

DAFTAR TABEL

Tabel 2.1	Rangkuman Penelitian Terkini	6
-----------	------------------------------------	---

DAFTAR GAMBAR

Gambar 3.1	Diagram Arsitektur Umum Sistem	9
Gambar 3.2	Arsitektur Model IndoBERT	12
Gambar 4.1	Training vs Validation Loss	16
Gambar 4.2	Training vs Validation Loss	17
Gambar 4.3	Confusion Matrix Clickbait	19
Gambar 4.4	Confusion Matrix Kategori Berita	20
Gambar 5.1	Parameter Percobaan 1	L-1
Gambar 5.2	Training Vs Validation Percobaan 1	L-1
Gambar 5.3	Training Loss Gabungan Percobaan 1	L-2
Gambar 5.4	Confusion Matrix Clickbait Percobaan 1	L-2
Gambar 5.5	Confusion Matrix Kategori Percobaan 1	L-3
Gambar 5.6	Report Percobaan 1	L-3
Gambar 5.7	Parameter Percobaan 3	L-4
Gambar 5.8	Training Vs Validation Percobaan 3	L-4
Gambar 5.9	Training Loss Gabungan Percobaan 3	L-4
Gambar 5.10	Confusion Matrix Clickbait Percobaan 3	L-5
Gambar 5.11	Confusion Matrix Kategori Percobaan 3	L-5
Gambar 5.12	Report Percobaan 3	L-6

BAB I

PENDAHULUAN

1.1 Latar Belakang

Di era digital, penggunaan *clickbait* telah menjadi praktik umum di berbagai portal berita daring. *Clickbait* merujuk pada teknik penyusunan judul yang dirancang untuk menarik perhatian pembaca secara sensasional guna membangkitkan rasa penasaran, namun kerap kali tidak mencerminkan konten artikel sebenarnya (Potthast et al., 2016).

Tujuan utama dari penggunaan *clickbait* adalah untuk meningkatkan jumlah klik atau *engagement*, yang pada akhirnya berdampak langsung terhadap pendapatan iklan dan peringkat *SEO* media tersebut (Y. Chen et al., 2015). Studi menunjukkan bahwa *clickbait* mampu meningkatkan metrik interaksi seperti *like*, *share*, dan *comment* di media sosial secara signifikan (Chakraborty et al., 2016).

Akan tetapi, strategi ini menimbulkan dampak negatif jangka panjang. Salah satu risikonya adalah menurunnya kepercayaan pembaca terhadap media yang sering menggunakan *clickbait*, terutama jika isi kontennya tidak memenuhi janji dari judul konten tersebut (Hurst, 2016). Media besar bahkan mulai membatasi penggunaan *clickbait* demi menjaga kredibilitas dan integritas *brand* mereka (Fakhruzzaman, Gunawan, et al., 2021).

Dari perspektif konsumen, *clickbait* dapat memicu rasa kecewa, karena menyebabkan kelelahan informasi (*information fatigue*), hingga menurunnya persepsi terhadap akurasi berita (Al Jazeera Institute, 2022).

Beberapa penelitian telah dilakukan untuk mendeteksi *clickbait* secara otomatis. Pendekatan awal banyak menggunakan fitur linguistik sederhana seperti panjang kalimat, rasio *stop-words*, dan *part-of-speech tag* (Chakraborty et al., 2016). Selanjutnya, pendekatan berbasis *neural network* seperti *CNN* dan *LSTM* mulai dikembangkan untuk meningkatkan akurasi (Anand et al., 2017).

Dengan munculnya model berbasis *pre-trained language model (PLM)* seperti *BERT* dan *IndoBERT*, performa klasifikasi judul *clickbait* meningkat signifikan, terutama untuk bahasa lokal seperti bahasa Indonesia (Devlin et al., 2018; Koto et al., 2020). (Fakhruzzaman, Gunawan, et al., 2021) menunjukkan bahwa penggunaan *Multilingual BERT* mampu mencapai *F1-score* sebesar 0,914 dalam mendeteksi *clickbait* judul berita berbahasa Indonesia.

Namun, sebagian besar penelitian terdahulu masih terbatas pada klasifikasi biner antara *clickbait* dan *non-clickbait* (Ahmad et al., 2020). Padahal, dalam praktiknya, *clickbait* memiliki berbagai gaya dan motif, seperti *listicle*, *teaser*, pertanyaan retorik,

dan sensasionalisme.

Selain itu, banyak pendekatan hanya menggunakan informasi dari judul, padahal relevansi antara judul dan isi artikel sangat penting untuk menilai apakah sebuah judul tergolong *clickbait* atau tidak (Wang et al., 2023). (Supriya et al., 2023) menunjukkan bahwa integrasi antara *embedding* judul dan potongan konten artikel mampu meningkatkan *F1-score* sebesar 8,8% dibandingkan pendekatan berbasis judul saja.

Dengan demikian, terdapat celah penelitian yang penting di mana belum banyak studi yang mengklasifikasikan *clickbait* secara multikelas dan memanfaatkan pendekatan multimodal dalam konteks bahasa Indonesia.

Oleh karena itu, penelitian ini mengusulkan Pendekatan *Multi-Task Learning* untuk Klasifikasi *Clickbait* Berbahasa Indonesia Menggunakan *IndoBERT*. Tujuannya adalah mengembangkan sistem deteksi *clickbait* berbasis *Large Language Model (LLM)* guna meningkatkan akurasi klasifikasi *clickbait*.

1.2 Rumusan Masalah

Judul berita bersifat *clickbait* sering kali menyimpang dari isi konten sebenarnya, sehingga mengurangi kepercayaan pembaca dan memicu penyebaran informasi menyesatkan. Sayangnya, sebagian besar pendekatan deteksi *clickbait* masih terbatas pada klasifikasi biner. Sementara di sisi lain, variasi kategori berita di Indonesia tidak seragam antarmedia. Oleh karena itu, penelitian ini mengusulkan pendekatan *Multi-Task Learning* untuk melakukan klasifikasi multikelas *clickbait* sekaligus klasifikasi kategori berita dalam konteks Indonesia.

1.3 Tujuan Penelitian

Penelitian ini bertujuan mengembangkan sistem klasifikasi *clickbait* berbasis *multi-task learning* untuk dua tugas klasifikasi sekaligus, yaitu untuk identifikasi multikelas *clickbait*, dan untuk klasifikasi kategori berita. Pendekatan ini mengatasi keterbatasan model sebelumnya yang terbatas pada klasifikasi biner (*clickbait/non-clickbait*) dan bersifat *single-task*.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi ilmiah di bidang Pemrosesan Bahasa Alami, khususnya dalam pengembangan model *multi-task learning* untuk klasifikasi jenis berita (*clickbait*) dan kategori berita. Secara praktis, pendekatan yang diusulkan diharapkan dapat meningkatkan akurasi deteksi *clickbait*, sehingga membantu masyarakat menghindari informasi menyesatkan dan menguatkan literasi digital. Lebih jauh, sistem ini berpotensi diadopsi oleh platform berita daring maupun media sosial guna menjaga integritas informasi dan membangun kepercayaan publik terhadap konten yang disajikan.

1.5 Batasan Penelitian

Dalam perancangan sistem ini, sejumlah batasan ditetapkan guna memperjelas fokus serta ruang lingkup studi yang dilakukan, yaitu sebagai berikut:

1. Penelitian ini menggunakan *dataset* yang dikumpulkan dari lima tahun terakhir, yang berasal dari berbagai sumber berita daring, seperti *Tribunnews*, *Detikcom*, *Kompas*, *Viva*, *Kumparan*, *Tempo*, dan *Liputan6*
2. *Dataset* yang digunakan mencakup sebanyak 4000 data, dengan komposisi judul dan isi berita.
3. Model yang diimplementasikan dalam penelitian ini meliputi *IndoBERT* untuk pengolahan data teks bahasa Indonesia.
4. Seluruh data yang dianalisis menggunakan bahasa Indonesia, yang tersedia pada media berita *online*.
5. Pelabelan dilakukan secara otomatis menggunakan *GPT* dan validasi ulang oleh 3 *annotator* orang yang fasih berbahasa Indonesia dan memahami konteks *clickbait* lokal, serta terbiasa membaca berita daring.

BAB II

LANDASAN TEORI

2.1 Pengertian dan Konsep Dasar

Berikut ini adalah beberapa istilah dan konsep dasar yang berkaitan dengan penelitian. Pemahaman terhadap istilah dan konsep dasar ini sangat penting untuk memberikan landasan teoritis yang kuat, serta untuk memastikan bahwa pembaca memiliki persepsi yang sama terhadap topik yang dibahas.

2.1.1 *Clickbait*

Clickbait adalah teknik pembuatan judul berita yang bersifat sensasional atau menyesatkan, bertujuan untuk menarik perhatian dan meningkatkan klik pengguna, sering kali dengan mengorbankan akurasi atau relevansi isi (Potthast et al., 2022). *Clickbait* dapat mengurangi kepercayaan publik terhadap media berita dan memicu penyebaran informasi yang tidak akurat.

Berdasarkan studi yang dilakukan oleh Chakraborty et al., 2020, lebih dari 25% *headline* di platform berita *online* menunjukkan karakteristik *clickbait*. Implikasi negatifnya termasuk menurunnya kredibilitas berita dan peningkatan penyebaran informasi *misleading*, yang dapat memperparah fenomena *echo chamber* dan *polarization* di media sosial.

2.1.2 *BERT*

BERT (*Bidirectional Encoder Representations from Transformers*) adalah model berbasis *transformer* yang dikembangkan oleh Devlin et al., 2019, memungkinkan pemahaman konteks kata berdasarkan semua kata di sekitarnya (*bidirectional*). *BERT* melakukan *pre-training* dengan dua tugas utama: *Masked Language Model* (MLM) dan *Next Sentence Prediction* (NSP), yang membuatnya unggul dalam berbagai tugas *NLP*.

Perkembangan model *BERT*, salah satunya adalah *IndoBERT*, yang disesuaikan dengan bahasa Indonesia. *IndoBERT* dilatih menggunakan korpus berbahasa Indonesia yang besar seperti *OSCAR* dan *Wikipedia* Indonesia, sehingga meningkatkan performa model untuk tugas-tugas *NLP* dalam bahasa Indonesia (Wilie et al., 2020).

2.1.3 Klasifikasi Kategori Berita

Klasifikasi kategori berita merupakan proses otomatis untuk mengidentifikasi dan menetapkan satu atau lebih kategori topik (seperti politik, olahraga, ekonomi, teknologi, atau hiburan) pada suatu artikel berita. Proses ini bersifat krusial guna pengorganisasian informasi, personalisasi konten, dan analisis tren berita (Kaur2020).

Dengan volume berita digital yang masif, klasifikasi akurat berperan vital dalam pengelolaan informasi, penjaminan akurasi, serta peningkatan akuntabilitas konten berita (alfando2023).

2.1.4 *Multi-Task Learning*

Multi-Task Learning (MTL) adalah paradigma *machine learning* di mana beberapa tugas terkait dipelajari secara simultan melalui representasi bersama (*shared representation*), memanfaatkan kesamaan dan perbedaan antartugas untuk meningkatkan generalisasi model dan efisiensi pembelajaran. Mekanisme ini bekerja melalui *inductive transfer*, di mana pengetahuan yang diperoleh dari satu tugas berfungsi sebagai *bias* induktif untuk tugas lain, sehingga memperkaya kemampuan representasi model.

Studi terbaru menjelaskan bahwa MTL mendorong *disentanglement* (pemisahan) representasi laten yang merefleksikan struktur geometris dunia nyata, memfasilitasi *zero-shot generalization* pada tugas baru. Fenomena ini diamati baik pada jaringan saraf biologis maupun arsitektur *transformer* modern, di mana pemrosesan paralel multi-tugas menghasilkan peta kognitif (*cognitive maps*) yang terstruktur.

2.2 Penelitian Terkini

Penelitian terkini dalam deteksi *clickbait* menunjukkan kemajuan signifikan melalui pendekatan multimodal dan integrasi *Large Language Models* (LLM). Untuk lebih jelas dapat dilihat pada Tabel 2.1 Rangkuman Penelitian Terkini.

Tabel 2.1. Rangkuman Penelitian Terkini

No	Nama Peneliti (Tahun)	Judul Penelitian	Keterangan
1	Yu et al. (2024)	<i>Multimodal Clickbait Detection by De-confounding Biases Using Causal Representation Inference</i>	Penelitian ini menggunakan inferensi kausal untuk menghilangkan <i>bias</i> pada data multimodal, meningkatkan akurasi dan generalisasi.
2	Z. Chen et al. (2023)	<i>Clickbait Detection via Large Language Models</i>	Penelitian ini mengevaluasi kinerja LLM seperti <i>ChatGPT</i> untuk deteksi <i>clickbait</i> <i>few-shot</i> dan <i>zero-shot</i> , stabilitas tinggi namun belum mengungguli <i>BERT</i> .
3	Zhang et al. (2024)	<i>Multi-modal Soft Prompt-tuning for Chinese Clickbait Detection. Neurocomputing</i>	Pada penelitian ini menggunakan metode <i>soft prompt-tuning</i> multimodal untuk teks dan gambar, meningkatkan akurasi deteksi <i>clickbait</i> dalam bahasa Mandarin.
4	Khan et al. (2025)	<i>Deep Learning and Sentence Embeddings for Detection of Clickbait in Urdu News Headlines. Scientific Reports</i>	Penelitian ini menggunakan <i>Bi-LSTM</i> dan <i>embedding</i> kalimat untuk deteksi <i>clickbait</i> dalam berita Urdu; mencapai akurasi 88%.

BAB III

METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini merupakan penelitian eksperimental dan pengembangan model dalam bidang Natural Language Processing yang berfokus pada pengembangan arsitektur inovatif. Penelitian termasuk dalam kategori applied research karena bertujuan menciptakan solusi praktis untuk masalah nyata dalam deteksi konten clickbait. Pendekatan multitask learning dipilih karena memungkinkan model belajar representasi teks yang lebih kaya melalui pembelajaran bersama dua tugas terkait (deteksi clickbait dan klasifikasi kategori), yang secara teoritis dapat meningkatkan generalisasi model dibandingkan pendekatan single-task. Penelitian ini juga termasuk riset kuantitatif karena melibatkan evaluasi metrik kinerja numerik untuk mengukur efektivitas model.

3.2 Pendekatan

Pendekatan multitask learning dengan arsitektur shared encoder dan task-specific heads diadopsi untuk memaksimalkan sinergi antara dua tugas klasifikasi. Model Transformer pra-terlatih IndoBERT berfungsi sebagai backbone yang mengekstrak fitur teks tingkat tinggi. Pendekatan ini memanfaatkan transfer learning untuk mengadaptasi pengetahuan linguistik yang telah dipelajari IndoBERT pada korpus bahasa Indonesia yang masif. Secara arsitektural, representasi vektor teks yang dihasilkan IndoBERT kemudian diumpankan ke dua classifier head terpisah yang dioptimalkan secara bersamaan selama pelatihan. Strategi ini memungkinkan pertukaran pengetahuan antar-tugas (knowledge transfer) sementara tetap mempertahankan spesialisasi masing-masing classifier.

3.3 Data

3.3.1 Sumber Data

Dataset utama penelitian bersumber dari web berita publik yang berisi berita bahasa Indonesia terkini. Data ini dipilih karena mencakup variasi topik berita yang luas kemudian dilakukan proses anotasi secara otomatis untuk label clickbait dan kategori berita. Keberadaan kolom isi artikel memberikan konteks tambahan yang krusial untuk analisis hubungan antara judul dan konten sebenarnya.

3.3.2 Karakteristik Data

Dataset mengandung 4 fitur utama dengan karakteristik unik:

- **judul:** Rata-rata panjang 10-15 kata dengan struktur linguistik khas headline

- **isi:** Konten artikel panjang (100-500 kata) yang memberikan konteks substantif
- **clickbait_label:** Distribusi kelasnya adalah exaggeration, misleading, non clickbait, teasing
- **kategori_berita:** 9 kelas dengan distribusi bervariasi (Bisnis, entertainment, kesehatan, kriminal, lifestyle, lingkungan, politik, sport, teknologi) yang mencerminkan minat pembaca Indonesia

3.3.3 Pra-pemrosesan Data

Proses pra-pemrosesan melibatkan beberapa tahap kritis:

- **Pemilihan Fitur:** Hanya mempertahankan fitur relevan untuk mengurangi noise
- **Deduplikasi:** Menghapus sampel duplikat untuk mencegah kebocoran data
- **Pembersihan Teks:** Menghilangkan karakter spesial dan whitespace berlebihan
- **Penanganan Missing Values:** Mengeliminasi sampel dengan data tidak lengkap
- **Normalisasi Label:** Transformasi label tekstual ke representasi numerik


3.3.4 Pembagian Dataset

Skema pembagian dataset dirancang untuk memenuhi tiga prinsip utama:

- **Representativitas:** Stratifikasi berdasarkan label clickbait menjamin distribusi kelas proporsional
- **Independensi:** Tidak ada tumpang-tindih sampel antar subset
- **Reproduktibilitas:** Penggunaan random state menjamin hasil konsisten

3.4 Arsitektur Umum Sistem

Arsitektur umum sistem yang dikembangkan dalam penelitian ini mengikuti alur kerja terstruktur mulai dari persiapan data hingga evaluasi model. Arsitektur umum pada penelitian ini terdiri dari komponen-komponen berikut:



Gambar 3.1. Diagram Arsitektur Umum Sistem

Arsitektur umum pada penelitian ini terdiri dari:

1. Instalasi Dependencies

Langkah awal dalam proyek ini adalah menginstal semua pustaka Python yang diperlukan seperti transformers, datasets, scikit-learn, torch, pandas, numpy, seaborn, dan matplotlib. Pustaka-pustaka ini esensial untuk mendukung seluruh alur kerja mulai dari pemrosesan data, pembangunan model, pelatihan, hingga visualisasi hasil. Instalasi dilakukan menggunakan pip dalam lingkungan Python virtual untuk memastikan versi pustaka yang kompatibel.

2. Baca Dataset

Dataset utama penelitian, yaitu KlikBERT_dataset.csv, dibaca ke dalam lingkungan kerja menggunakan pandas. Dataset ini berisi informasi berita dalam bahasa Indonesia dengan kolom-kolom penting seperti judul berita, isi artikel, label clickbait (dengan kategori: misleading, non clickbait, teasing, exaggeration), dan kategori berita (politik, kriminal, bisnis, kesehatan, entertainment, lingkungan, sport, teknologi, lifestyle).

3. Preprocessing Data

Tahap preprocessing meliputi empat langkah utama: (1) Penghapusan kolom tidak perlu seperti 'url' yang tidak relevan untuk analisis, (2) Penghapusan baris duplikat baik secara keseluruhan maupun berdasarkan kombinasi unik judul dan isi, (3) Penghapusan baris dengan nilai kosong atau string kosong setelah stripping pada kolom penting, dan (4) Konversi label tekstual menjadi representasi numerik menggunakan LabelEncoder dari scikit-learn untuk mempersiapkan data input model.

4. Split Data Train/Validation/Test

Dataset yang telah diproses dibagi menjadi tiga subset dengan proporsi 70% untuk training, 15% untuk validasi, dan 15% untuk testing. Pembagian dilakukan secara stratified berdasarkan label clickbait untuk mempertahankan distribusi kelas yang seimbang di setiap subset. Penggunaan random_state=42 menjamin hasil pembagian yang konsisten dan dapat direproduksi.

5. Tokenisasi dengan IndoBERT Tokenizer

Teks dari kolom judul dan isi digabungkan kemudian di-tokenisasi menggunakan AutoTokenizer dari model IndoBERT. Proses ini melibatkan penambahan token khusus [CLS] di awal dan [SEP] di akhir teks, pemotongan teks yang melebihi 512 token dengan prioritas konten utama, serta penambahan padding untuk teks yang lebih pendek agar semua input memiliki panjang seragam. Output tokenisasi berupa input_ids dan attention_mask.

6. Buat PyTorch Dataset

Data hasil tokenisasi dan label numerik dikemas ke dalam kelas Dataset kustom yang diwarisi dari torch.utils.data.Dataset. Kelas ini mengimplementasikan metode __ge-

titem__ untuk mengembalikan dictionary berisi input_ids, attention_mask, serta label numerik untuk kedua tugas (clickbait dan kategori) dalam format yang kompatibel dengan PyTorch DataLoader.

7. Bangun Model Multitask IndoBERT

Arsitektur model dibangun berdasarkan model pra-terlatih IndoBERT (indobenchmark/indobert-base-p1) dengan penambahan dua head klasifikasi: (1) Clickbait Classifier berupa lapisan linear dengan 4 unit output untuk 4 kelas clickbait, dan (2) Category Classifier berupa lapisan linear terpisah dengan 9 unit output untuk 9 kategori berita. Dropout sebesar 0.3 diterapkan sebelum head klasifikasi untuk regularisasi.

8. Custom Multitask Loss Function

Diimplementasikan fungsi loss kustom yang menghitung CrossEntropyLoss secara terpisah untuk masing-masing tugas klasifikasi clickbait dan kategori. Total loss merupakan penjumlahan dari kedua loss individu ($\text{loss} = \text{loss_clickbait} + \text{loss_kategori}$). Fungsi ini diintegrasikan dengan meng-override metode compute_loss pada trainer.

9. Setup TrainingArguments

Konfigurasi pelatihan ditetapkan melalui TrainingArguments yang menentukan: jumlah epoch (10), batch size (8), learning rate ($2e-5$), frekuensi evaluasi (setiap 21 langkah), strategi penyimpanan (menyimpan model terbaik berdasarkan eval_loss), dan penggunaan mixed precision training (fp16) untuk optimasi GPU.

10. Trainer Class dengan compute_metrics

Kelas trainer kustom diimplementasikan dengan meng-override metode compute_loss untuk menangani perhitungan loss multitask. Selain itu, kelas ini juga mencatat loss individual untuk setiap tugas selama pelatihan guna pemantauan kinerja per tugas.

11. Jalankan Training

Proses pelatihan dijalankan dengan memanggil metode train() pada objek trainer. Model belajar dari data training selama 10 epoch sambil melakukan evaluasi berkala pada data validasi. Progres pelatihan dan metrik evaluasi dicatat secara otomatis.

12. Visualisasi Loss & Akurasi

Setelah pelatihan selesai, dilakukan visualisasi metrik kinerja menggunakan matplotlib dan seaborn. Grafik yang dihasilkan meliputi: (1) Perbandingan training loss vs validation loss per epoch, (2) Tren loss gabungan, loss clickbait, dan loss kategori per langkah pelatihan, serta (3) Grafik akurasi validasi jika diperlukan.

13. Evaluasi Model

Evaluasi komprehensif dilakukan pada data validasi menggunakan classification report (precision, recall, f1-score, support) dan confusion matrix untuk masing-masing tugas klasifikasi. Metrik akurasi keseluruhan juga dihitung untuk kedua tugas.


14. Simpan Model ke .bin

Model terlatih beserta konfigurasi tokenizer disimpan dalam format .bin menggunakan torch.save. Penyimpanan mencakup state_dict model, konfigurasi tokenizer, serta metadata penting lainnya untuk memungkinkan loading model di lingkungan produksi.

3.5 Arsitektur Model

3.5.1 Model Indobert

Model ini dibangun berdasarkan arsitektur IndoBERT, yaitu model BERT (Bidirectional Encoder Representations from Transformers) yang telah dilatih khusus untuk bahasa Indonesia. Arsitektur ini mengikuti struktur dasar BERT namun diterapkan pada tugas multitask classification, yaitu mendeteksi clickbait dan mengklasifikasikan kategori berita secara bersamaan.



Gambar 3.2. Arsitektur Model IndoBERT

Berikut adalah penjabaran setiap komponen arsitektur Model IndoBERT:

1. Input Ganda: Judul dan Isi Berita

Model menerima dua buah teks sebagai input:

- Judul berita
- Isi berita

Setiap bagian input akan diproses secara paralel namun terpisah, yang artinya judul dan isi akan diperlakukan sebagai dua urutan token berbeda yang dimasukkan ke IndoBERT secara independen.

2. Tokenisasi dan Embedding

Masing-masing teks di-tokenisasi dan dibubuhi token khusus:

[CLS] Token Token ... Token [SEP]

Token [CLS] digunakan sebagai representasi agregat dari keseluruhan teks. Token [SEP] menandai akhir dari input.

Setiap token akan diubah menjadi representasi vektor melalui tiga komponen embedding:

- Token Embedding: representasi dari masing-masing kata/token
- Segment Embedding: menunjukkan segmen mana (judul atau isi) token tersebut berasal
- Positional Embedding: menyandikan posisi token dalam urutan kalimat

Ketiga embedding dijumlahkan untuk menghasilkan vektor input akhir E_i .

3. IndoBERT Encoder

Vektor embedding dari masing-masing token kemudian dimasukkan ke dalam encoder IndoBERT yang terdiri dari beberapa lapisan transformer. Di sinilah proses pembelajaran representasi kontekstual dilakukan melalui mekanisme self-attention dan feed-forward neural networks.

Output dari masing-masing bagian (judul dan isi) adalah sekumpulan vektor representasi kontekstual:

Judul: $h_{[CLS]_{\text{judul}}}, h_1, h_2, \dots, h_n$

Isi: $h_{[CLS]_{\text{isi}}}, h_1, h_2, \dots, h_m$

Dari setiap bagian, hanya vektor dari token [CLS] yang digunakan untuk tahap klasifikasi, karena vektor ini mengandung ringkasan semantik dari seluruh teks input.

4. Penggabungan Representasi

Vektor [CLS] dari judul dan isi digabungkan (biasanya dengan konkatenasi):

$$h_{\text{gabung}} = [h_{[CLS]_{\text{judul}}}; h_{[CLS]_{\text{isi}}}]$$

Vektor gabungan ini menyatukan informasi global dari kedua input teks dan menjadi input untuk tahap klasifikasi berikutnya.

5. Layer Klasifikasi

Vektor hasil gabungan kemudian diteruskan ke dua layer klasifikasi terpisah:

- Linear Layer + Softmax untuk Clickbait Detection
- Linear Layer + Softmax untuk Kategori Berita

Setiap layer klasifikasi terdiri dari:

- **Linear layer (fully connected):** mengubah dimensi representasi menjadi sesuai dengan jumlah kelas
- **Softmax:** menghasilkan distribusi probabilitas antar kelas

Hasil dari kedua classifier ini adalah:

- `clickbait_label`: label apakah berita bersifat clickbait atau tidak
- `kategori_label`: label kategori/topik berita seperti politik, olahraga, hiburan, dll.

6. Multi-task Learning

Model dilatih dengan dua fungsi loss:

- $L_{\text{clickbait}}$
- L_{kategori}

Kedua loss ini digabungkan (misalnya dengan penjumlahan berbobot) untuk melakukan pembaruan parameter model secara simultan:

$$L_{\text{total}} = \alpha \cdot L_{\text{clickbait}} + \beta \cdot L_{\text{kategori}}$$

Model ini dibangun berdasarkan arsitektur IndoBERT, sebuah model transformer-based yang telah dilatih secara khusus untuk bahasa Indonesia. Arsitektur ini dimodifikasi untuk mendukung multi-task classification, yaitu mendeteksi apakah suatu berita bersifat clickbait dan menentukan kategori berita secara simultan.

3.5.2 Model Dasar (Backbone)

IndoBERT (indobenchmark/indobert-base-p1) dipilih sebagai encoder utama karena performa teruji pada tugas NLP bahasa Indonesia. Model ini memiliki 12 lapisan transformer dengan 110 juta parameter, mampu menangkap kontekstualitas bahasa Indonesia yang kompleks. Representasi vektor [CLS] (768 dimensi) digunakan sebagai input untuk task-specific heads.

3.5.3 Struktur Head Multitask

Arsitektur head multitask terdiri dari tiga komponen kunci:

- **Representation Layer:** Dropout ($p=0.3$) untuk mitigasi overfitting
- **Clickbait Classifier:** Dense layer dengan 4 unit output + softmax
- **Category Classifier:** Dense layer dengan 9 unit output + softmax

Kedua classifier berbagi representasi teks yang sama namun memiliki parameter terpisah untuk spesialisasi tugas.

3.6 Proses Pelatihan

3.6.1 Tokenisasi

Proses tokenisasi mengadopsi skema subword khusus IndoBERT dengan penanganan khusus untuk:

- **Truncation:** Memotong teks >512 token dengan prioritas konten utama
- **Padding:** Menyamakan panjang input untuk pemrosesan batch
- **Segment Embedding:** Membedakan judul dan isi dengan token [SEP]

3.6.2 Strategi Pelatihan

Pelatihan menggunakan tiga teknik utama:

- **Custom Loss Function:** Kombinasi bobot Cross Entropy loss untuk kedua tugas
- **Gradient Accumulation:** Mengakomodasi batch size kecil (8)
- **Early Stopping:** Berdasar validation loss dengan toleransi 3 epoch

3.6.3 Konfigurasi Hyperparameter

Optimasi hyperparameter menggunakan pendekatan informed choice:

- **Learning Rate:** $2e-5$ (optimal untuk fine-tuning BERT)
- **Batch Size:** 8 (disesuaikan kapasitas GPU)
- **Epochs:** 10 (cukup untuk konvergensi tanpa overfitting)
- **Weight Decay:** 0.01 untuk regularisasi

3.7 Lingkungan Komputasi

Eksperimen dilakukan pada lingkungan dengan spesifikasi:

- **GPU:** NVIDIA RTX 2080 Ti x4 (12GB VRAM)
- **Framework:** PyTorch 2.2 + Transformers 4.38
- **Optimasi:** CUDA 12.2 + cuDNN 8 untuk akselerasi
- **Virtual Environment:** Python 3.10 dengan isolasi dependensi


BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Pelatihan

Proses pelatihan model IndoBERT multitask dilakukan selama 10 epoch. Pemantauan loss selama pelatihan menunjukkan tren yang signifikan pada training loss dan validation loss, serta loss individual untuk masing-masing tugas (clickbait dan kategori berita).

4.1.1 Grafik Training vs Validation Loss (per Epoch)




Gambar 4.1. Training vs Validation Loss

Grafik ini menunjukkan bagaimana loss model berkembang selama pelatihan. Training loss (garis biru) menunjukkan penurunan yang konsisten dan drastis sepanjang 10 epoch, mencapai nilai yang sangat rendah di akhir pelatihan. Ini mengindikasikan bahwa model berhasil mempelajari dan menyesuaikan diri dengan pola dalam data pelatihan.

Namun, validation loss (garis oranye) menunjukkan tren yang sedikit berbeda. Meskipun validation loss menurun di awal epoch (sekitar epoch 1-2), setelah itu cenderung stabil dan bahkan sedikit meningkat di beberapa epoch terakhir. Pola ini merupakan indikasi kuat adanya overfitting. Model kemungkinan besar mulai menghafal data pelatihan daripada mempelajari fitur-fitur yang dapat digeneralisasi ke data yang tidak terlihat (data validasi).

4.1.2 Grafik Training Loss (Gabungan, Clickbait, & Kategori)



Gambar 4.2. Training vs Validation Loss

Grafik ini memberikan wawasan lebih detail mengenai kontribusi loss dari setiap tugas terhadap loss gabungan (total loss). Terlihat bahwa loss gabungan (garis biru), loss clickbait (garis oranye), dan loss kategori (garis hijau) semuanya menunjukkan penurunan yang serupa dan konsisten sepanjang step pelatihan. Ini menunjukkan bahwa model berhasil mengoptimalkan kedua tugas secara bersamaan melalui pendekatan multitask learning dengan penjumlahan loss. Penurunan yang selaras ini juga menegaskan bahwa tidak ada satu tugas pun yang sepenuhnya mendominasi proses pembelajaran model.

4.2 Hasil Evaluasi Model

Evaluasi model dilakukan pada validation set menggunakan classification report dan accuracy score dari pustaka Scikit-learn.

4.2.1 Classification Report - Clickbait

Kelas	Precision	Recall	F1-score	Support
exaggeration	0.71	0.79	0.74	150
misleading	0.89	0.86	0.88	146
non clickbait	0.86	0.78	0.82	161
teasing	0.76	0.77	0.76	161
accuracy			0.80	618
macro avg	0.80	0.80	0.80	618
weighted avg	0.80	0.80	0.80	618

Model mencapai akurasi keseluruhan sebesar 79.77% untuk tugas deteksi clickbait. Performansi bervariasi antar kelas:

'misleading' menunjukkan F1-score tertinggi (0.88), yang berarti model cukup baik dalam mengidentifikasi jenis clickbait ini. Recall yang tinggi (0.86) menunjukkan model mampu menangkap sebagian besar kasus 'misleading'.

'non clickbait' memiliki precision yang sangat tinggi (0.86), mengindikasikan bahwa ketika model memprediksi 'non clickbait', prediksinya sangat akurat. Namun, recall yang lebih rendah (0.82) menyiratkan bahwa model mungkin melewatkan beberapa kasus 'non clickbait' yang sebenarnya.

'exaggeration' dan 'teasing' memiliki performa yang sedikit lebih rendah, dengan F1-score masing-masing 0.74 dan 0.76. Ini mungkin menunjukkan bahwa nuansa antara kelas-kelas clickbait ini lebih sulit ditangkap oleh model, atau bahwa batas definisinya lebih ambigu.

4.2.2 Classification Report - Kategori Berita

Kategori	Precision	Recall	F1-score	Support
bisnis	0.86	0.89	0.87	61
entertainment	0.88	0.87	0.88	122
kesehatan	0.84	0.85	0.85	62
kriminal	0.78	0.77	0.78	52
lifestyle	0.81	0.83	0.82	109
lingkungan	0.90	0.85	0.88	33
politik	0.88	0.95	0.91	92
sport	0.98	0.93	0.96	61
teknologi	0.73	0.62	0.61	26
accuracy			0.86	618
macro avg	0.85	0.84	0.84	618
weighted avg	0.86	0.86	0.86	618

Model menunjukkan performa yang lebih baik pada tugas klasifikasi kategori berita, dengan akurasi keseluruhan sebesar 85.92%. Performansi antar kategori umumnya tinggi:


Kategori seperti 'sport' (F1-score 0.96), 'bisnis' (0.87), 'lingkungan' (0.88), dan 'politik' (0.91) menunjukkan kinerja yang sangat baik. Ini mungkin karena ciri khas leksikal atau kontekstual yang jelas pada kategori-kategori ini.

Kategori 'teknologi' dan 'kriminal' memiliki F1-score yang relatif lebih rendah

(masing-masing 0.67 dan 0.78). Ini bisa disebabkan oleh beberapa faktor, seperti ukuran support (jumlah sampel) yang lebih kecil untuk 'teknologi' dibandingkan kategori lain, atau adanya tumpang tindih tema dengan kategori lain.

Secara keseluruhan, model multitask ini menunjukkan bahwa ia lebih efektif dalam mengklasifikasikan kategori berita dibandingkan dengan mendeteksi clickbait. Perbedaan ini mungkin disebabkan oleh kompleksitas inheren dari tugas clickbait yang seringkali melibatkan pemahaman yang lebih halus tentang gaya bahasa dan niat penulis, dibandingkan dengan klasifikasi kategori yang lebih fokus pada konten tematik.

4.2.3 Confusion Matrix Clickbait




Gambar 4.3. Confusion Matrix Clickbait

Gambar 4.3 memperlihatkan nilai-nilai diagonal utama (118, 126, 125, 124) merepresentasikan jumlah prediksi benar (*true positive*) untuk masing-masing kelas, menunjukkan bahwa model secara umum memiliki kinerja yang baik dengan akurasi di atas 80% untuk semua kategori. Namun, beberapa pola misklasifikasi yang signifikan terutama: 27 sampel *exaggeration* yang terklasifikasi sebagai *teasing*, dan 18 sampel *teasing* yang teridentifikasi sebagai *exaggeration*. Fenomena ini mengindikasikan adanya *overlap* semantik

atau kesamaan fitur linguistik antarkelas tersebut.

4.2.4 Confusion Matrix - Kategori Berita



Gambar 4.4. Confusion Matrix Kategori Berita

Gambar 4.4 menampilkan matriks klasifikasi sembilan kategori konten dengan akurasi bervariasi. Nilai diagonal utama menunjukkan prediksi benar tertinggi pada kategori *entertainment* (106), sementara kategori *lingkungan* mengalami kesalahan total (28 sampel terklasifikasi sebagai *lifestyle*) dan *teknologi* hanya mencapai 16 prediksi benar. Model menunjukkan kesulitan utama dalam membedakan *lifestyle* dengan *entertainment* (10 sampel salah klasifikasi dua arah) dan *lingkungan* dengan *lifestyle* (28 sampel), mengindikasikan kesamaan karakteristik konten antar kategori-kategori tersebut.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini berhasil mengembangkan dan melatih model *multi-task learning* berbasis *IndoBERT* untuk melakukan dua tugas klasifikasi secara bersamaan: klasifikasi *clickbait* dan klasifikasi kategori berita. Model ini memanfaatkan arsitektur *Transformer* pra-trlatih *IndoBERT*, yang kemudian disesuaikan dengan dua *head* klasifikasi terpisah untuk masing-masing tugas. Pendekatan *multi-task learning* dengan penjumlahan *loss* dari kedua tugas memungkinkan model untuk belajar representasi fitur yang kaya dan saling menguntungkan dari teks berita.

Hasil evaluasi menunjukkan bahwa model mencapai akurasi sebesar 79,77% untuk tugas klasifikasi *clickbait* dan 85,92% untuk tugas klasifikasi kategori berita. Meskipun terdapat indikasi *overfitting* pada data pelatihan yang terlihat dari tren *validation loss*, model masih menunjukkan kemampuan generalisasi yang baik, terutama pada tugas klasifikasi kategori. Analisis *confusion matrix* lebih lanjut mengonfirmasi bahwa model lebih akurat dalam mengidentifikasi kategori berita dibandingkan dengan nuansa *clickbait*.

Secara keseluruhan, model *multi-task* ini menunjukkan potensi yang menjanjikan dalam aplikasi pengolahan bahasa alami untuk bahasa Indonesia, membuktikan bahwa *IndoBERT* dapat diadaptasi secara efektif untuk tugas-tugas kompleks seperti klasifikasi *clickbait* dan klasifikasi berita.

Namun, analisis *error* menunjukkan bahwa model kesulitan membedakan kategori *clickbait* seperti *teasing* dan *exaggeration*, yang dapat disebabkan oleh potensi kesalahan label atau ambiguitas definisi kategori dalam *dataset*. Oleh karena itu, diperlukan peningkatan kualitas dan konsistensi anotasi untuk mendukung kinerja model yang lebih akurat ke depannya.

5.2 Saran

Berdasarkan hasil dan pembahasan yang telah disampaikan, berikut adalah beberapa saran untuk penelitian dan pengembangan model di masa mendatang:

1. Mengimplementasikan penanganan *overfitting* yang lebih lanjut, seperti penggunaan mekanisme *early stopping* yang lebih agresif, eksplorasi nilai *dropout* yang berbeda, penambahan regularisasi seperti L1/L2, serta penerapan teknik *augmentasi* data teks seperti *back-translation* atau *synonym replacement* untuk meningkatkan keragaman data pelatihan.

2. Melakukan *hyperparameter tuning* yang lebih sistematis dan ekstensif dengan memanfaatkan alat bantu seperti *Optuna*, *Ray Tune*, atau *Hyperopt*, serta mengoptimalkan parameter seperti *learning rate*, *batch size*, jumlah *epoch*, dan nilai *dropout*, termasuk eksplorasi kombinasi bobot *loss* untuk tugas deteksi *clickbait* dan klasifikasi kategori.
3. Mengeksplorasi arsitektur *head* klasifikasi yang lebih kompleks, misalnya dengan menambahkan satu atau lebih lapisan *dense* (`nn.Linear`) dan fungsi aktivasi non-linear seperti *ReLU* sebelum lapisan *classifier* akhir, guna meningkatkan kapasitas representasi model.
4. Menambah dan mendiversifikasi data pelatihan, terutama untuk kelas-kelas dengan jumlah sampel terbatas seperti kategori 'teknologi', serta memfokuskan analisis pada kelas-kelas yang menunjukkan performa rendah dalam hasil evaluasi model.
5. Melakukan validasi ulang terhadap label, khususnya pada kategori *clickbait* seperti *teasing* dan *exaggeration*, yang menunjukkan tingkat kesalahan prediksi relatif tinggi. Hal ini bertujuan untuk memastikan konsistensi anotasi dan mengurangi *bias* data yang dapat menghambat performa model secara keseluruhan.
6. Menyusun pedoman anotasi (*annotation guideline*) yang lebih ketat dan eksplisit untuk membantu anotator dalam membedakan jenis-jenis *clickbait* secara konsisten, serta mempertimbangkan pelibatan lebih dari satu anotator dan perhitungan tingkat kesepakatan (misalnya *Cohen's Kappa*) sebagai bagian dari proses validasi kualitas *dataset*.

DAFTAR PUSTAKA

- Ahmad, I., Alqarni, M. A., Almazroi, A. A., & Tariq, A. (2020). Experimental evaluation of clickbait detection using machine learning models. *Intelligent Automation & Soft Computing*, 26(6), 1335–1347. <https://doi.org/10.32604/iasc.2020.013861>
- Al Jazeera Institute. (2022). The impact of clickbait on media trust and reader fatigue.
- Anand, A., Chakraborty, T., & Park, N. (2017). We used neural networks for clickbait detection and you won't believe the results! *arXiv preprint arXiv:1702.05638*. <https://arxiv.org/abs/1702.05638>
- Chakraborty, A., Paranjape, B., Kakarla, S., & Ganguly, N. (2020). Stop clickbait: Detecting clickbaits in news streams using deep learning. *Online Social Networks and Media*, 19, 100103. <https://doi.org/10.1016/j.osnem.2020.100103>
- Chakraborty, A., Paranjape, B., Kakarla, S., & Ganguly, N. (2016). Stop clickbait: Detecting and preventing clickbaits in online news media. *arXiv preprint arXiv:1610.09786*. <https://arxiv.org/abs/1610.09786>
- Chen, Y., Conroy, N. J., & Rubin, V. L. (2015). Misleading online content: Clickbait and misinformation. *Proceedings of the 2015 ACM on Workshop on Multimodal Deception Detection*. <https://doi.org/10.1145/2818346.2820760>
- Chen, Z., Hu, L., Li, W., Shao, Y., & Nie, L. (2023). Clickbait detection via large language models [Preprint]. *arXiv preprint*. <https://arxiv.org/abs/xxxx.xxxxx>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*. <https://arxiv.org/abs/1810.04805>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186. <https://doi.org/10.48550/arXiv.1810.04805>
- Fakhruzzaman, D., Gunawan, D., et al. (2021). Clickbait headline detection in Indonesian news sites. *Indonesian Journal of Information Systems*, 4(1), 24–31. <https://doi.org/10.21070/ijins.v4i1.1177>
- Hurst, M. (2016). Evaluating the effects of clickbait on news credibility. *ResearchGate*. https://www.researchgate.net/publication/325460445_Evaluating_the_Effects_of_Clickbait_on_News_Credibility
- Khan, A., Ahmad, S., & Ali, M. (2025). Deep learning and sentence embeddings for detection of clickbait in Urdu news headlines. *Scientific Reports*, 20, xxxxx. <https://doi.org/10.1038/s41598-025-xxxxx>
- Koto, F., Rahmaningtyas, F., & Nurdiansyah, A. (2020). Indobert: A pretrained language model for Indonesian. *arXiv preprint arXiv:2009.05387*. <https://arxiv.org/abs/2009.05387>


- Potthast, M., Gollub, T., Komlossy, K., Schöchlin, S., & Stein, B. (2022). Clickbait detection: A comparative study. *Information Processing & Management*, 59(1), 102770. <https://doi.org/10.1016/j.ipm.2021.102770>
- Potthast, M., Köpsel, S., Stein, B., & Hagen, M. (2016). Clickbait detection. *Advances in Information Retrieval*, 810–817.
- Supriya, Singh, J. P., & Kumar, G. (2023). Identification of clickbait news articles using sbert and correlation matrix. *Social Network Analysis and Mining*, 13, 153. <https://doi.org/10.1007/s13278-023-01162-0>
- Wang, H., Zhu, Y., Wang, Y., Li, Y., Yuan, Y., & Qiang, J. (2023). Clickbait detection via large language models. *arXiv preprint arXiv:2306.09597*. <https://arxiv.org/abs/2306.09597>
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., & Purwarianti, A. (2020). IndoBERT: A pre-trained language model for indonesian. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. <https://doi.org/10.48550/arXiv.2009.05387>
- Yu, J., Wang, S., Yin, H., Sun, Z., Xie, R., Zhang, B., & Rao, Y. (2024). Multimodal clickbait detection by de-confounding biases using causal representation inference [Preprint]. *arXiv preprint*. <https://arxiv.org/abs/xxxx.xxxxx>
- Zhang, Y., Liu, X., & Wang, Y. (2024). Multi-modal soft prompt-tuning for chinese clickbait detection. *Neurocomputing*, 30, xxx–xxx. <https://doi.org/10.1016/j.neucom.2024.xxxxxx>

LAMPIRAN


L.1 Percobaan Pertama

```
training_args = TrainingArguments(  
    output_dir="./results",  
    num_train_epochs=3,  
    per_device_train_batch_size=8,  
    per_device_eval_batch_size=8,  
    eval_steps=100, 21  
    learning_rate=2e-5,  
    evaluation_strategy="steps",  
    save_strategy="epoch",  
    save_total_limit=1,  
    logging_dir="./logs",  
    logging_steps=100, 21  
    logging_strategy="steps",  
    report_to="none",  
    remove_unused_columns=False  
)
```


Gambar 5.1. Parameter Percobaan 1




Gambar 5.2. Training Vs Validation Percobaan 1



Gambar 5.3. Training Loss Gabungan Percobaan 1



Gambar 5.4. Confusion Matrix Clickbait Percobaan 1



Gambar 5.5. Confusion Matrix Kategori Percobaan 1

	precision	recall	f1-score	support
exaggeration	0.71	0.79	0.74	150
misleading	0.89	0.86	0.88	146
non clickbait	0.86	0.78	0.82	161
teasing	0.76	0.77	0.76	161
accuracy			0.80	618
macro avg	0.80	0.80	0.80	618
weighted avg	0.80	0.80	0.80	618

	precision	recall	f1-score	support
bisnis	0.86	0.89	0.87	61
entertainment	0.88	0.87	0.88	122
kesehatan	0.84	0.85	0.85	62
kriminal	0.78	0.77	0.78	52
lifestyle	0.81	0.83	0.82	109
lingkungan	0.90	0.85	0.88	33
politik	0.88	0.95	0.91	92
sport	0.98	0.93	0.96	61
teknologi	0.73	0.62	0.67	26
accuracy			0.86	618
macro avg	0.85	0.84	0.84	618
weighted avg	0.86	0.86	0.86	618


✧ [Kategori]
Accuracy: 0.8592233009708737
✧ [Clickbait]
Accuracy: 0.7977346278317152

Gambar 5.6. Report Percobaan 1


L.2 Percobaan Tiga

```
training_args = TrainingArguments(  
    output_dir="./results",  
    num_train_epochs=10, # learning rate yang umum digunakan, hyperparameter ini bisa disesuaikan  
    per_device_train_batch_size=8,  
    per_device_eval_batch_size=8,  
    eval_steps=21,  
    save_steps=21,  
    learning_rate=2e-5, # learning rate yang umum digunakan, hyperparameter ini bisa disesuaikan  
    evaluation_strategy="steps",  
    save_strategy="steps",  
    save_total_limit=1,  
    logging_dir="./logs",  
    logging_steps=21,  
    logging_strategy="steps",  
    report_to="none",  
    remove_unused_columns=False,  
    metric_for_best_model="eval_loss", # Tentukan metrik untuk model terbaik  
    load_best_model_at_end=True,      # Muat model terbaik di akhir training  
    greater_is_better=False           # Karena metriknya loss, nilai lebih kecil lebih baik  
)
```


Gambar 5.7. Parameter Percobaan 3




Gambar 5.8. Training Vs Validation Percobaan 3



Gambar 5.9. Training Loss Gabungan Percobaan 3



Gambar 5.10. Confusion Matrix Clickbait Percobaan 3



Gambar 5.11. Confusion Matrix Kategori Percobaan 3

	precision	recall	f1-score	support
exaggeration	0.67	0.74	0.70	150
misleading	0.76	0.90	0.83	146
non clickbait	0.90	0.73	0.80	161
teasing	0.79	0.73	0.76	161
accuracy			0.77	618
macro avg	0.78	0.78	0.77	618
weighted avg	0.78	0.77	0.77	618
	precision	recall	f1-score	support
bisnis	0.86	0.92	0.89	61
entertainment	0.88	0.86	0.87	122
kesehatan	0.84	0.84	0.84	62
kriminal	0.76	0.79	0.77	52
lifestyle	0.81	0.84	0.83	109
lingkungan	0.88	0.88	0.88	33
politik	0.90	0.87	0.88	92
sport	0.98	0.93	0.96	61
teknologi	0.75	0.69	0.72	26
accuracy			0.86	618
macro avg	0.85	0.85	0.85	618
weighted avg	0.86	0.86	0.86	618

✧ [Kategori]

Accuracy: 0.8576051779935275

✧ [Clickbait]

Accuracy: 0.7734627831715211

Gambar 5.12. Report Percobaan 3